CodificaMed

Informe ejecutivo | Base de Conocimiento, ESPOCH | Actualización: 03/11/2026

Problemática y objetivo

La codificación clínica requiere identificar enfermedades, síntomas, hallazgos y antecedentes, relacionarlos con un catálogo y revisar si cada mención está confirmada, negada, descartada o es sospechosa. El objetivo fue desarrollar un prototipo académico de asistencia a codificación con evidencia literal, dos modelos intercambiables y evaluación reproducible. El codificador humano revisa las sugerencias; el sistema no realiza diagnósticos médicos.

CRISP-ML(Q): 1. Comprensión del negocio y los datos

Se delimitó el catálogo a CIE-10-ES diagnóstico, edición 2018, con 71,486 códigos. Se descargaron CodiEsp gold 1.4 y su catálogo oficial. Se validaron 500 documentos train, 250 dev y 250 test. No se incorporaron historias clínicas privadas. CodiEsp es el corpus público permitido por la consigna; los ejemplos propios son enteramente ficticios. No se mezclaron procedimientos CodiEsp-P con las métricas de diagnóstico.

2. Preparación de datos

Se verificaron rutas del ZIP, estructura TSV, lectura UTF-8, correspondencia entre notas y gold, y los códigos del catálogo. Los archivos de origen se conservaron; data/manifest.json registra URL y SHA-256. El gold D contiene categorías ausentes del catálogo: 230 anotaciones train, 106 dev y 143 test. No se inventaron códigos ni se eliminaron esas etiquetas: permanecen en el denominador de recall.

Para ampliar las variantes de lenguaje se incorporaron únicamente anotaciones DIAGNOSTICO de trainX.tsv compatibles con train D y el catálogo. Se excluyeron procedimientos y no se incorporaron frases de dev o test al índice. La nota original se conserva para validar evidencia y offsets. La normalización y expansión de abreviaturas se aplican a la recuperación, sin borrar negaciones de la entrada del modelo.

3. Modelado

No se entrenaron pesos de los LLM. El modelado comprende TF-IDF de caracteres (3-5) y palabras (1-2), similitud coseno ponderada (0,35 y 0,65), variantes clínicas de train y coincidencias literales. Se agregaron 3275 pares código-frase de train. El recuperador prioriza coincidencias y reserva candidatos por fragmento. La decisión y la validación de cada mención siguen separadas.

En los 250 documentos dev, 40 candidatos cubrieron 1836/2677 códigos gold (0.6858); 60 cubrieron 0.7124. Se mantuvieron 40 para limitar el contexto local. En los mismos dos documentos dev anteriores, la cobertura pasó de 6/39 a 23/39. Este dato evalúa recuperación, no precisión del LLM.

4. Evaluación

Se calcularon TP, FP y FN sobre conjuntos de códigos distintos y confirmados por documento. La métrica principal es micro-F1, con micro-precisión y micro-recall. También se registra F1 promedio por documento, que no equivale a macro por etiqueta. Un FP es un código ausente del gold de ese documento; no implica necesariamente un código inexistente en el catálogo.

El error anterior fue principalmente de recuperación: en los tres documentos examinados, apenas 4/34 códigos gold estaban entre los candidatos. También hubo selección de códigos con evidencia literal semánticamente inadecuada. Se conservaron los resultados anteriores, se ajustó con train/dev y casos ficticios, y se retiraron esos tres documentos de la nueva muestra final. No se ajustó el sistema después de observar las predicciones de la muestra nueva.

El nuevo piloto selecciona un caso de cada quintil de cantidad de códigos gold, mediante SHA-256 de una semilla fija y el ID. Se excluyen los tres casos retirados y notas que exceden el presupuesto de entrada. El plan conserva IDs, gold, hash de texto, candidatos y huella del pipeline y sus recursos. Ambos modelos reciben exactamente los mismos casos, candidatos e instrucciones. El comparador rechaza discrepancias y permite comparar únicamente el subconjunto común si una API se interrumpe.

5. Despliegue

La interfaz Streamlit permite elegir Ollama o Gemini, pegar una nota ficticia o pública de CodiEsp, cargar ejemplos, revisar códigos y evidencias resaltadas, marcar revisión y descargar JSON. Oculta resultados anteriores si cambia la entrada o el modelo. Qwen utiliza Ollama local; Gemini utiliza el SDK oficial google-genai. Se corrigió una incompatibilidad del esquema con response_json_schema y se mantuvo la validación Pydantic posterior.

La clave se carga desde .env privado y no se incluye en la entrega. No se descargaron otros modelos, no se activó facturación y no se publicó el proyecto. El entorno conserva Python 3.13 y dependencias fijadas. El README contiene instalación, preparación del corpus, ejecución, evaluación y reanudación de checkpoints.

6. Monitoreo y mantenimiento

Los JSON y CSV conservan códigos predichos, FP, FN, evidencias, estados originales y corregidos, rechazos y tiempos. El contador de API registra modelo, huella del prompt y estado HTTP, sin claves ni notas completas. Limita solicitudes y separa generaciones para reducir presión sobre la cuota gratuita. Ante 429 se detiene; ante interrupciones se conservan casos válidos y se reanuda sin repetirlos ni mezclar versiones.

Arquitectura

Streamlit o CLI → nota original y fragmentación → TF-IDF del catálogo y variantes de train → hasta 40 candidatos → prompt y esquema comunes → Qwen/Ollama o Gemini → validación de código, evidencia, calificadores y estado → revisión humana. La evaluación reutiliza este recorrido. Los módulos de datos, recuperación, inferencia, límites de API, experimentos y métricas están separados.

La validación rechaza códigos inexistentes o fuera de candidatos y evidencia no literal. Exige soporte textual para lateralidad, bilateralidad e in situ. No convierte un valor numérico aislado en un hallazgo elevado. Las reglas distinguen no se descarta de se descarta, respetan cláusulas y conservan menciones contradictorias. Estas reglas son controles parciales, no un validador clínico completo.

Evaluación y comparación de modelos

Piloto final: 5 documentos comunes, con los mismos textos, códigos gold, candidatos y versión del pipeline. Se calcularon las métricas únicamente sobre diagnósticos confirmados. Las categorías de estado no están anotadas en CodiEsp-D y no se les asigna una supuesta precisión de negación.

Modelo	Precisión	Recall	F1	TP	FP	FN
Qwen 3.5:4b	0.6364	0.2456	0.3544	14	8	43
Gemini 3.5 Flash-Lite	0.8400	0.3684	0.5122	21	4	36

Recuperación compartida: 40/57 etiquetas gold entre candidatos. La cobertura limita el recall posible, pero no garantiza que el LLM seleccione el código correcto.

Tiempos transcurridos de procesamiento de notas: Qwen 707.24 s; Gemini 76.15 s. Excluyen la construcción inicial del índice. Gemini incluye la espera del limitador local; no es un benchmark aislado de velocidad del proveedor.

Selección reproducible: semilla CodificaMed-2026-11-03-v2. Un caso por quintil de carga de códigos; 245 documentos elegibles antes de filtrar por presupuesto del prompt. Es un piloto de diversidad de carga, no una muestra estadísticamente representativa de toda la clínica.

Documento	Quintil	Gold	Caracteres
S1137-66272014000100019-1	1	3	1682
S1134-80462009000100005-1	2	6	835
S0004-06142008000600014-1	3	10	2529
S0004-06142009000500013-1	4	16	1323
S0212-16112012000600045-1	5	22	2685

Huella de pipeline y recursos: e39eebe923750a44c5d049992c8562c6f2efa0c977338920c4f498c90ba0f50c

Qwen: intentos rechazados antes de las métricas: 1 por código inexistente, 9 por evidencia no literal.

Gemini: intentos rechazados antes de las métricas: 3 por código fuera de candidatos, 1 por evidencia no literal, 2 por lateralidad no sustentada.

Controles enteramente ficticios

Se evaluaron S02 y S06: negación, confirmación, descarte, sospecha y nota mixta, con cuatro pares código-estado esperados. Son controles de desarrollo separados de CodiEsp; no constituyen validación clínica independiente. Las contradicciones también están cubiertas por pruebas automatizadas.

Modelo	F1 código	F1 código-estado	Neg./desc. confirmados	Neg./desc. omitidos
Qwen	1.0000	0.8571	0	1
Gemini	1.0000	1.0000	0	0

Neg./desc. confirmados cuenta confirmaciones indebidas donde se esperaba negación o descarte. Neg./desc. omitidos cuenta menciones negativas no recuperadas: Qwen omitió la mención negada de S02. Son errores distintos. La exactitud de pares registra también otros cambios y omisiones; no se traslada a CodiEsp-D.

Evaluación: evidencia técnica

Pytest: 39 casos, 0 fallos, 0 errores y 0 omitidos. Incluye corpus real, recuperación, validación literal y calificadores, negación, contradicciones, métricas, reanudación, límites de API y rechazo de comparaciones incompatibles. Los mocks verifican contratos, no calidad de los LLM.

Gemini: interfaz comprobada con una llamada real y evidencia textual.

Qwen: interfaz comprobada con una llamada real y evidencia textual.

Control de API: 12 solicitudes de generación contabilizadas; respuestas 200: 9, 400: 2, 503: 1, 429: 0. Los dos 400 correspondieron al esquema inicial; el 503 de la interfaz se resolvió con un único reintento manual. No se ejecutaron lotes masivos ni reintentos automáticos.

El modelo configurado fue localizado y generó contenido con la clave del proyecto. La tarifa oficial ofrece entrada y salida gratuitas para este modelo. El nivel gratuito del proyecto fue informado por el usuario: el SDK utilizado no certifica el estado de facturación de la cuenta. No se activó facturación ni se invocaron servicios adicionales de pago.

La auditoría de entrega verificó la regla .env en .gitignore, su ausencia en la lista de archivos de entrega y ausencia de la clave en código, documentos y resultados revisados. No existe repositorio Git local en este workspace y no se publicó un remoto.

Conclusiones y limitaciones

En los mismos 5 documentos, Qwen obtuvo micro-F1=0.3544 y Gemini=0.5122. Las omisiones fueron 43 y 36, respectivamente. La recuperación mejoró en dev frente al sistema anterior, pero no elimina los errores de selección o especificidad. La muestra antigua y la nueva son diferentes: no se interpreta su diferencia de F1 como una mejora causal medida sobre el mismo test.

Cinco documentos no respaldan generalización a práctica clínica. Los calificadores y las reglas de estado cubren situaciones concretas y no resuelven toda coordinación, alcance, temporalidad ni relación entre diagnóstico y código. Evidencia literal no garantiza corrección semántica. El catálogo corresponde a CIE-10-ES 2018; no se validó adaptación al catálogo ecuatoriano ni a ediciones actuales.

La ejecución local está limitada por CPU y memoria: contexto 4096, salida máxima 1600 tokens y timeout 600 s. Gemini recibe los mismos datos y criterios con temperatura 0, pero opera en otro servicio y sus límites internos no son iguales a los de Qwen. El contador preventivo local es configurable y no equivale a la cuota oficial de Google. Se debe conservar la versión del experimento antes de modificar recursos o prompts.

Pendiente del estudiante: grabar un video de más de 10 minutos, mostrar el funcionamiento y mantener el rostro visible en una sección de pantalla. La publicación se mantiene sin ejecutar por instrucción del usuario. No se inventó video ni URL de repositorio.

Fuentes

CodiEsp gold 1.4: https://zenodo.org/records/3837305

Catálogo CIE-10-ES 2018: https://zenodo.org/records/3632523

Tarea y anotación CodiEsp: https://temu.bsc.es/codiesp/

CRISP-ML(Q): https://www.mdpi.com/2504-4990/3/2/392

Ollama, salidas estructuradas: https://docs.ollama.com/capabilities/structured-outputs

Gemini, tarifa oficial: https://aistudio.google.com/docs/pricing#gemini-3.5-flash-lite